1 第四章基于 IBA 的 ELM 预测模型构建

1.1 标准蝙蝠算法的缺陷分析

蝙蝠算法（BA）是一类模拟蝙蝠回声定位行为的群智能优化算法，具有实现简洁、参数相对较少等特点。然而在连续优化问题中，标准 BA 容易出现两类典型现象：一是早期下降后较快进入“平台区”，二是后期改进幅度有限，收敛过程呈现拖尾。下面结合基准函数上的收敛曲线对这一现象进行说明。

首先标准蝙蝠算法易陷入局部最优，从图 1 可见，标准 BA 在前若干次迭代后其最优适应度下降趋缓，并较早进入相对稳定的平台区；相对而言，IBA 在相同迭代次数下可继续降低最优适应度，说明其在搜索过程中保持了更强的改进能力。

其次后期收敛慢，可见标准 BA 在中后期的曲线变化幅度明显减小；而 IBA 曲线在中后期仍保持缓慢下降趋势，表明 IBA 对“后期收敛拖沓”的问题具有一定缓解作用。

最后为更直观量化比较两种算法的收敛行为，本节在 Sphere function 上绘制 BA 与 IBA 的“最优适应度（Best fitness）—迭代次数（Iteration）”曲线，如图 1 所示。该图的纵轴采用对数尺度（log scale），阴影带表示多次重复实验的波动范围（例如均值 ± 标准差），以反映算法稳定性差异：标准 BA 的波动范围更大，而 IBA 的收敛更快且更稳定。

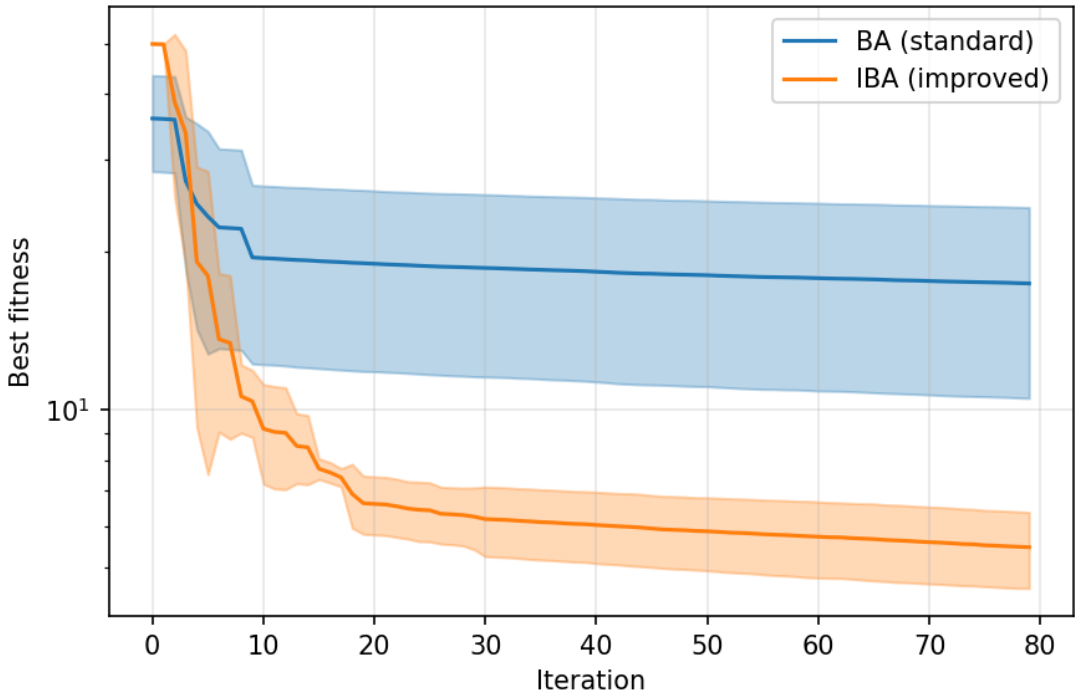

Figure 1: BA 与 IBA 在 Sphere function 上的收敛曲线对比（纵轴为 log 标度；阴影带表示多次运行的波动范围）

1.2 蝙蝠算法的改进策略（IBA）

针对标准 BA 在收敛速度与稳定性方面的不足，本研究构建 IBA，并重点从两个环节进行增强：(1) 利用混沌序列提升初始种群的遍历性与多样性；(2) 引入自适应惯性权重 $w(t)$，实现从全局搜索到局部开发的平滑过渡。两项改进分别对应图 2 与图 3 的示意结果。

1.2.1 引入混沌映射（Tent/Logistic）提升初始种群多样性

随机初始化在高维空间中可能导致种群分布不均。为增强初始种群的遍历性，本研究采用混沌映射生成 $x_n \in (0,1)$ 的序列，并通过线性映射将其转换到各维搜索边界 $[lb, ub]$，以构造初始位置向量。图 2 给出了 Tent 与 Logistic 两类混沌序列的典型形态，用于直观说明其非周期性与遍历特征。

Tent 映射

$$x_{n+1} = \mu \cdot \min(x_n, 1 - x_n), \quad \mu = 2. \tag{1}$$

Logistic 映射

$$x_{n+1} = \mu \cdot x_n(1 - x_n), \quad \mu = 4. \tag{2}$$

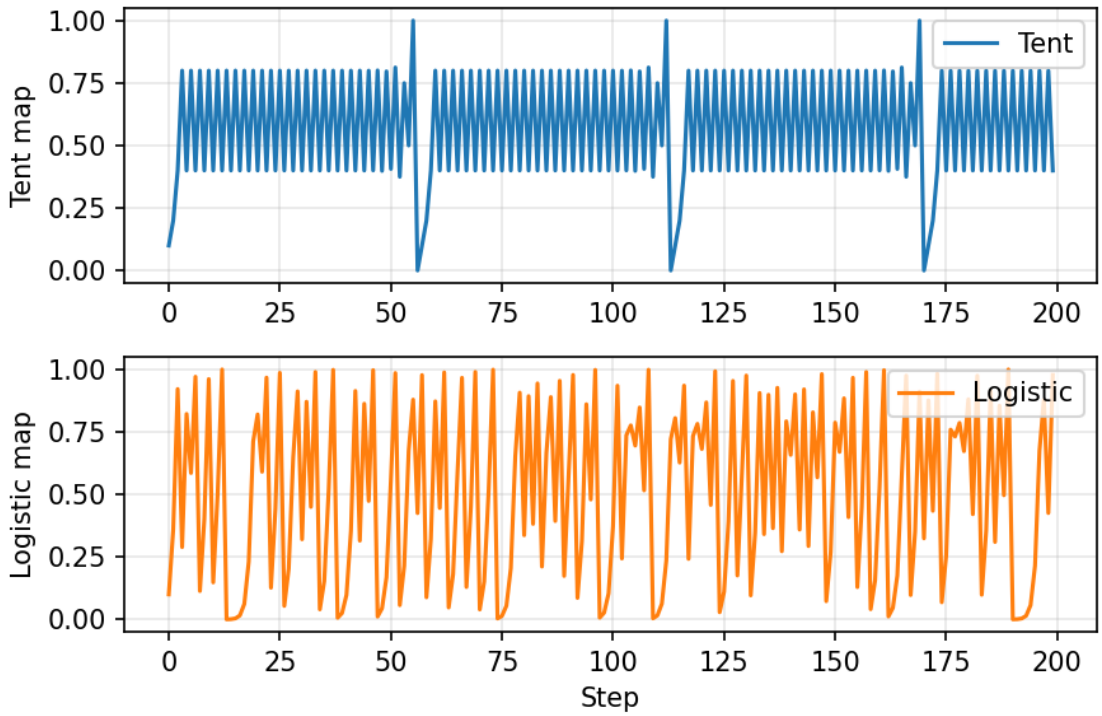

Figure 2: Tent 与 Logistic 混沌序列示意（用于构造更具遍历性的初始种群）

1.2.2 引入自适应惯性权重平衡全局与局部搜索能力

为改善中后期收敛变慢的问题，在速度更新中引入惯性权重 $w(t)$，使算法在迭代前期保持较强探索能力，在迭代后期更偏向局部开发。惯性权重采用线性递减策略，其变化趋势如图 3 所示（由 0.9 线性下降至 0.4）。

$$\mathbf{v}_i^{t+1} = w(t)\mathbf{v}_i^t + (\mathbf{x}_i^t - \mathbf{x}_{best}^t) \cdot f_i, \tag{3}$$

$$w(t) = w_{\max} - \frac{t}{T}\left(w_{\max} - w_{\min}\right), \tag{4}$$

其中 T 为最大迭代代数，$w_{\max} = 0.9$，$w_{\min} = 0.4$。

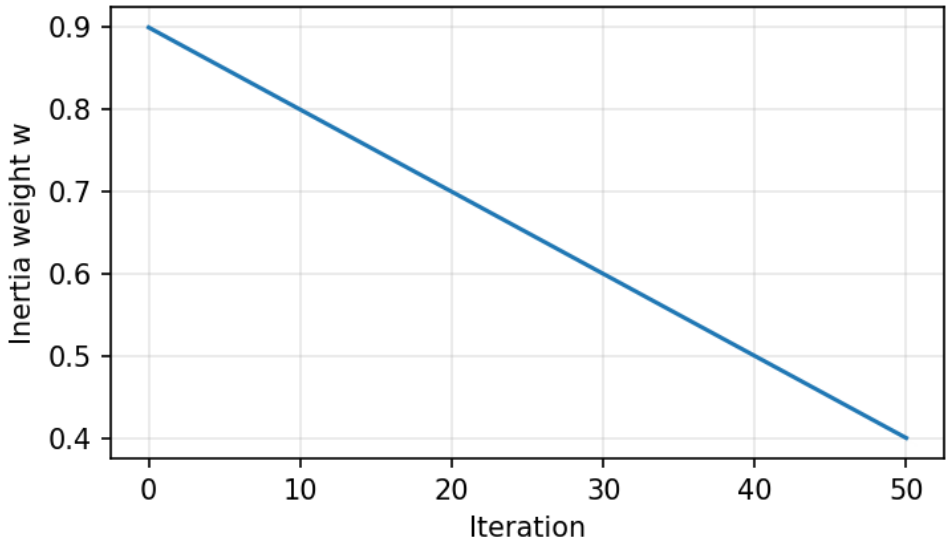

Figure 3: 自适应惯性权重 $w(t)$ 的线性递减示意（$0.9 \to 0.4$，体现全局搜索向局部开发的过渡）

1.2.3 引入精英保留策略防止种群退化

为进一步提升寻优过程的稳定性，IBA 可采用精英保留（elitism）策略：每代迭代后保留适应度最优的若干个体，以避免优良解在随机更新过程中丢失。该策略属于实现层面的稳定化手段，不改变图 3 所示的核心改进机制（混沌初始化与惯性权重调节）。

1.3 IBA 优化 ELM 模型的融合设计

ELM 为单隐层前馈网络，其输出权重可通过最小二乘一次求解，训练速度较快。但输入层权重与隐层偏置的随机初始化会带来性能波动。为提升模型稳定性，本研究采用 IBA 对 ELM 的输入权重与隐层偏置进行寻优，得到 IBA-ELM 模型。

1.3.1 适应度函数设计

为与图 4 左侧“K-fold CV RMSE”曲线一致，适应度函数定义为 K 折交叉验证 RMSE 的平均值。对候选解 $\mathbf{x}$（对应一组 ELM 的 $\mathbf{W}_{in}$ 与 $\mathbf{b}$），第 k 折验证集上的 RMSE 记为 $\mathrm{RMSE}^{(k)}(\mathbf{x})$，则：

$$\mathcal{F}(\mathbf{x}) = \frac{1}{K}\sum_{k=1}^{K}\mathrm{RMSE}^{(k)}(\mathbf{x}), \tag{5}$$

并以 $\min \mathcal{F}(\mathbf{x})$ 为优化目标。

1.3.2 蝙蝠位置映射机制

设输入维度为 n_{in}，隐层节点数为 n_{hidden}。待优化参数为输入层权重矩阵 $\mathbf{W}_{in} \in R^{n_{in}\times n_{hidden}}$ 与隐层偏置 $\mathbf{b} \in R^{n_{hidden}}$。将其向量化编码为：

$$\mathbf{x} = \Big[\mathrm{vec}(\mathbf{W}_{in});\, \mathbf{b}\Big] \in R^{D}, \quad D = n_{in}\cdot n_{hidden} + n_{hidden}. \tag{6}$$

给定 $\mathbf{x}$ 后，可重构得到 $(\mathbf{W}_{in}, \mathbf{b})$ 并计算式 (5) 的适应度。

1.3.3 IBA-ELM 模型整体运行流程与算法复杂度分析

IBA-ELM 的训练与预测流程如下：

1. **数据准备：**加载两季日尺度数据，构造特征向量与目标变量 ET_c，并进行标准化处理。
2. **参数设置：**设置隐层节点数 n_{hidden}；设置 IBA 参数（种群规模 n_{pop}、最大迭代代数 T、频率范围等），并设置交叉验证折数 K 与搜索边界 $[lb, ub]$。
3. **编码维度：**根据式 (6) 确定优化维度 D。
4. **IBA 寻优：**使用混沌序列初始化种群；迭代更新（含自适应惯性权重）并评估 K 折 RMSE 适应度，得到最优解 $\mathbf{x}^\star$。
5. **解码训练：**将 $\mathbf{x}^\star$ 解码为 $(\mathbf{W}_{in}^\star, \mathbf{b}^\star)$，训练得到最终 ELM 模型。
6. **预测评估：**输出预测值并绘制（1）K 折 CV RMSE 随迭代变化的收敛曲线；（2）标准化后的观测值与预测值散点拟合图（与图 4 一致）。

单次适应度评估需要进行 K 折 ELM 训练与验证。设样本量为 n，隐层节点数为 n_{hidden}，则每折包含隐层输出计算与输出权重求解，整体可近似为：

$$\mathcal{O}\big(K\cdot(n\cdot n_{hidden} + n_{hidden}^2)\big). \tag{7}$$

IBA 每代评估 n_{pop} 个体，共 T 代，因此总复杂度近似为：

$$\mathcal{O}\big(n_{pop}\cdot T\cdot K\cdot(n\cdot n_{hidden} + n_{hidden}^2)\big). \tag{8}$$

可以看出，算法复杂度主要受种群规模、迭代次数以及隐层节点数影响。虽然 IBA 引入了额外优化过程，但该过程仅涉及参数搜索，并不改变 ELM 输出权重的解析求解特性，因此整体计算复杂度仍保持在可接受范围内，适用于中等规模数据集的预测任务。

1.3.4 收敛与拟合效果展示

图 4 左侧给出了 IBA-ELM 在寻优过程中 K 折交叉验证 RMSE 的收敛曲线；右侧为标准化后的观测值（Observed, standardized）与预测值（Predicted, standardized）散点图，并绘制参考线 $y = x$ 以便直观对比预测一致性。

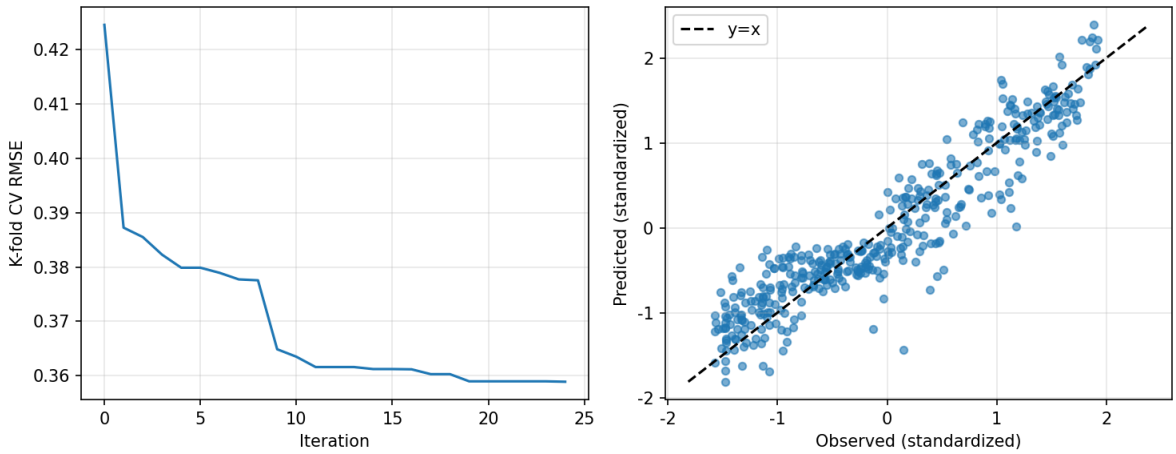

Figure 4: IBA-ELM 的寻优收敛过程与拟合效果：左为 K 折 CV RMSE 随迭代变化；右为标准化观测值与标准化预测值散点图（虚线为 $y = x$）

1.4 本章小结

本章围绕冬小麦日尺度 ET_c 预测任务构建 IBA-ELM 模型，并结合图示结果完成如下工作：

（1）在 Sphere function 上对比展示 BA 与 IBA 的收敛曲线（对数纵轴与多次运行波动带），结果表明 IBA 收敛更快且稳定性更好，标准 BA 更易进入平台区且后期改进幅度有限；

（2）给出 IBA 的两项核心改进：利用 Tent/Logistic 混沌序列增强初始种群遍历性，并采用线性递减惯性权重实现全局搜索向局部开发的过渡（$w(t) : 0.9 \to 0.4$）；

（3）将 IBA 与 ELM 融合：以 K 折交叉验证 RMSE 为适应度函数，完成对 ELM 输入权重与隐层偏置的向量化编码与连续寻优，并展示 IBA-ELM 在本任务上的 CV-RMSE 收敛曲线与标准化拟合散点图。

基于本章模型构建结果，下一章将进一步从评价指标体系与对比实验角度对模型预测性能进行系统评估。

2 第五章模型预测性能评估与对比分析

本章在第四章所构建的 IBA-ELM 模型基础上，从收敛行为、消融实验、综合预测精度以及分生育期误差分布等方面，对模型性能进行系统评估与对比分析。对比模型包括 BA-ELM、PSO-ELM、原始 ELM，以及传统机器学习方法 MLP。

2.1 IBA 算法优化性能验证

2.1.1 适应度收敛曲线对比

图 5 展示了 IBA-ELM、PSO-ELM 与原始 ELM 在迭代过程中的 K-fold CV RMSE 变化情况。

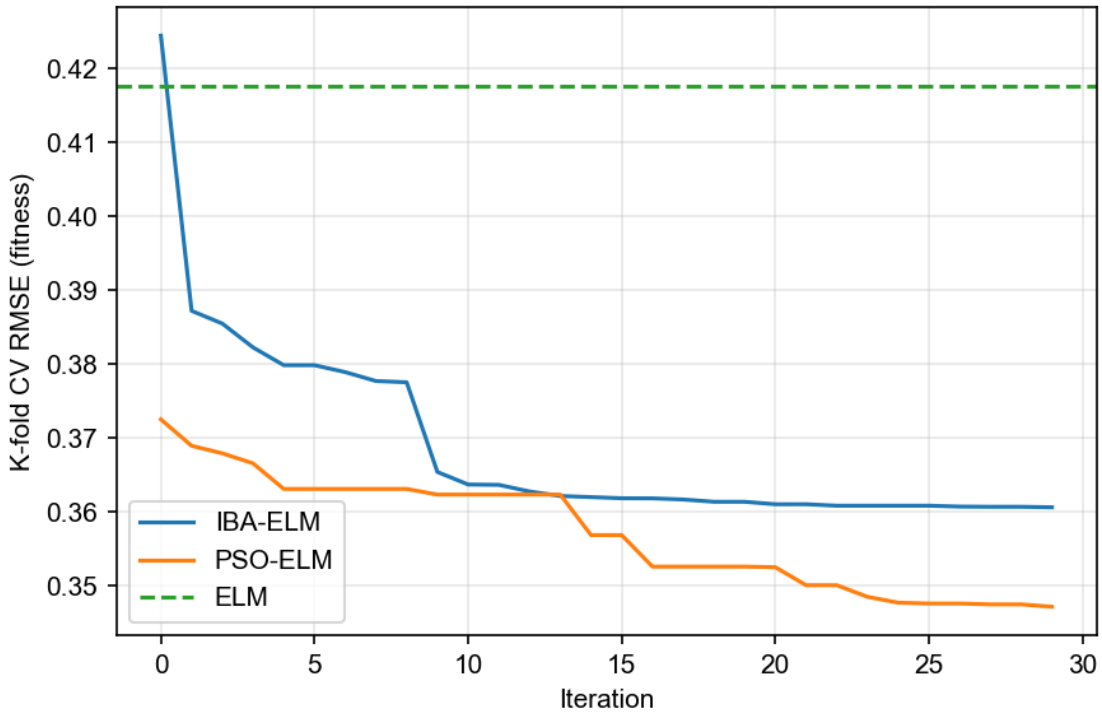

Figure 5: IBA-ELM、PSO-ELM 与 ELM 的收敛曲线对比

从图中可以观察到：

（1）原始 ELM 为固定值（无迭代优化），其 RMSE 水平高于两种群智能优化模型；

（2）IBA-ELM 在前 10 次迭代内快速下降，随后趋于稳定；

（3）PSO-ELM 在整个迭代过程中持续下降，最终达到更低的 RMSE 水平。

结果表明，两种群智能优化算法均能显著改善原始 ELM 的性能，其中 PSO-ELM 在最终 RMSE 上略优于 IBA-ELM，而 IBA-ELM 收敛速度较快、早期下降更明显。

2.1.2 混沌初始化与精英策略影响

为验证混沌初始化与精英保留策略对 IBA 性能的影响，进行消融实验，对比 IBA(full)、IBA(no chaos) 与 IBA(no elite)。

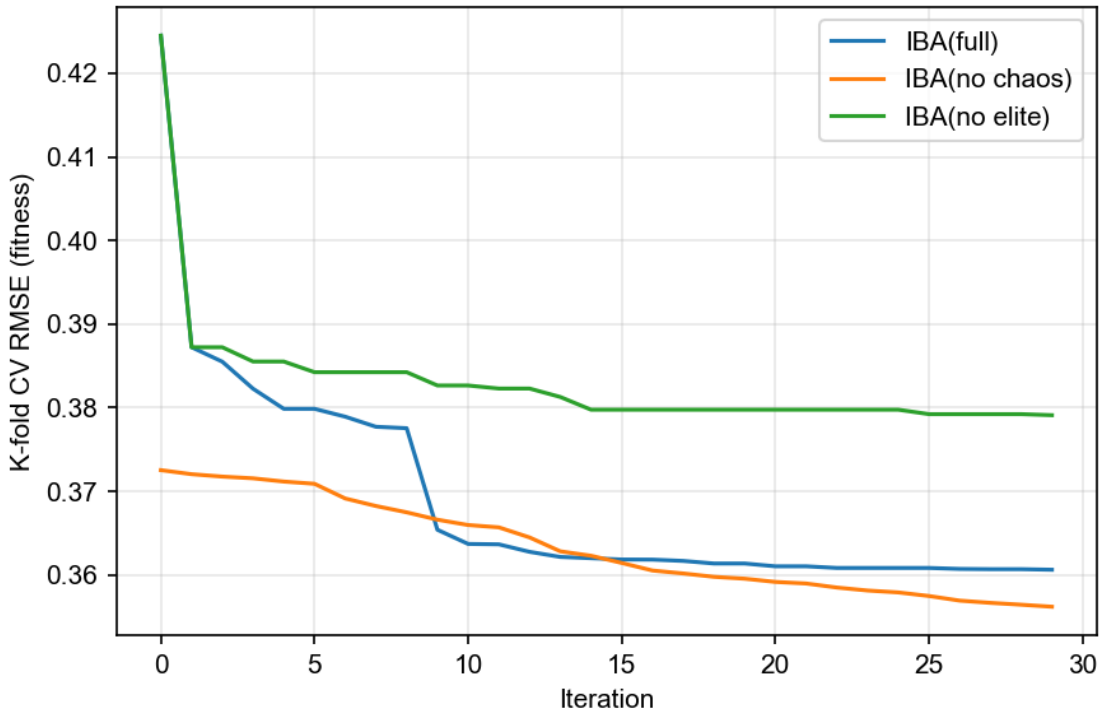

Figure 6: IBA 消融实验结果（混沌初始化与精英策略）

由图 6 可见:

（1）去除精英策略后，模型收敛效果明显下降，最终 RMSE 最高;

（2）去除混沌初始化后，整体收敛趋势仍保持下降，但最终性能略优于 full 版本;

（3）完整 IBA 结构整体稳定，收敛过程平滑。

说明精英策略对稳定性具有显著作用，而混沌初始化更多影响初始阶段的搜索多样性。

2.2 全气象要素输入下的 ETc 预测结果对比

2.2.1 预测精度对比

图 7 给出了不同模型在 R^2、RMSE 与 MAE 指标下的对比结果。

可以观察到:

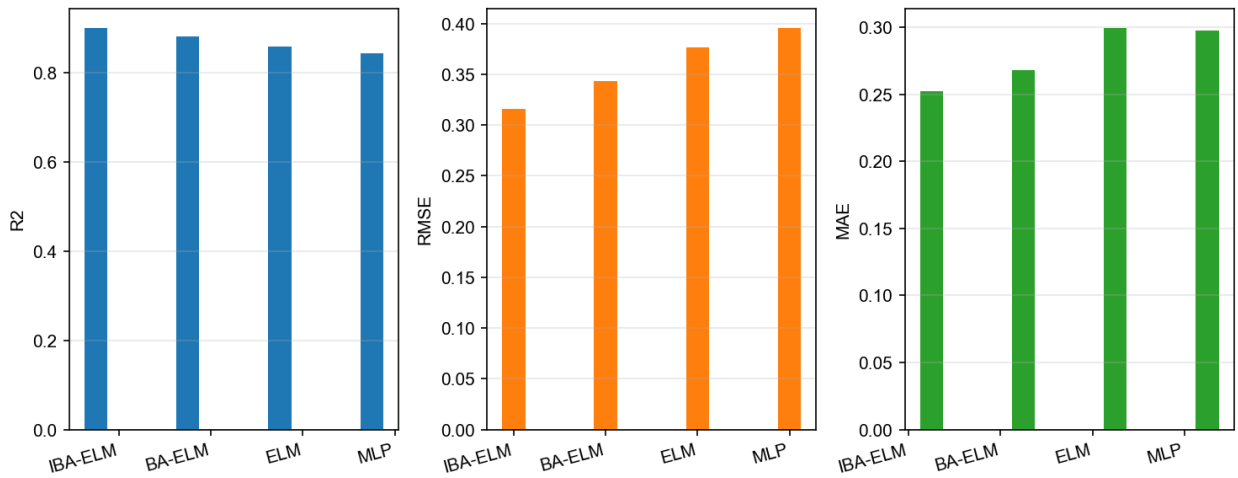

Figure 7: 不同模型的整体预测精度对比

(1) IBA-ELM 在三个评价指标上均表现最优，其 R^2 达到 0.9002，为所有模型中最高，说明其对目标变量具有最强拟合能力；同时其 RMSE 与 MAE 分别为 0.3160 和 0.2524，均为最低，表明其预测误差最小，预测结果最接近真实观测值，具有更高的预测精度与稳定性。

(2) BA-ELM 的整体性能次于 IBA-ELM，但优于原始 ELM，说明群智能优化算法能够有效改善 ELM 随机初始化带来的参数不稳定问题，从而提升模型性能。进一步比较可知，IBA-ELM 相比 BA-ELM 在 R^2 指标上进一步提高，同时 RMSE 与 MAE 均有所降低，表明所提出的改进策略在参数寻优过程中能够获得更优解，提高模型预测能力。

(3) 原始 ELM 与 MLP 的预测性能整体低于优化后的 ELM 模型，其中 MLP 的 RMSE 达到 0.3952，为所有模型中最高，说明其预测误差较大，在本数据集上的适应能力相对较弱。这表明，仅依赖随机初始化或传统训练方式的模型，在复杂非线性预测任务中难以获得最优参数配置。

进一步地，以原始 ELM 为基准，IBA-ELM 在 R^2 指标上提升约 4.88%，同时 RMSE 降低约 16.05%。这一结果表明，通过群智能优化算法对 ELM 输入权重与隐层偏置进行全局搜索，可以获得更优参数组合，从而有效降低预测误差，提高模型预测精度。

综合分析可知，IBA-ELM 性能提升的主要原因在于其优化机制的改进：一方面，通过混沌初始化提高种群分布均匀性，增强了解空间的全局搜索能力；另一方面，通过自适应惯性权重调节搜索强度，使算法在搜索后期能够进行更精细的局部优化，从而获得更优网络参数配置。因此，IBA-ELM 能够在拟合能力与预测精度方面取得更优表现，验证了所提出改进策略在 ELM 参数优化中的有效性。

Table 1: Performance comparison of different models

Model	R^2	RMSE	MAE
IBA-ELM	0.9002	0.3160	0.2524
BA-ELM	0.8820	0.3435	0.2683
ELM	0.8583	0.3764	0.2994
MLP	0.8438	0.3952	0.2976

2.2.2 冬小麦不同生育期的预测误差特征分析

为分析模型在不同生育阶段的适应能力，图 8 给出了各阶段 RMSE 分布。

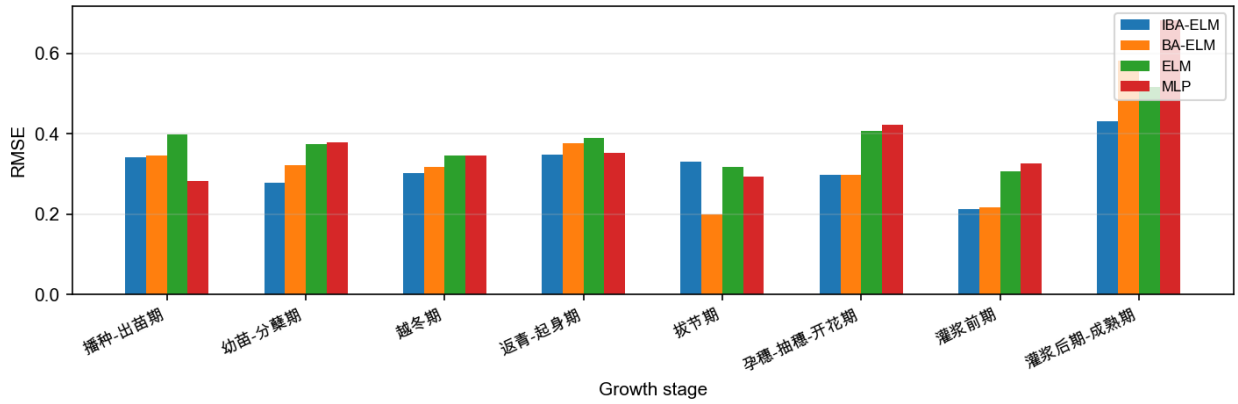

Figure 8: 不同生育阶段的预测误差对比

结果显示，各模型在不同生育阶段的预测误差呈现出明显的阶段性差异，反映出冬小麦蒸散过程在不同生长阶段的复杂性及其对气象因子的响应敏感程度存在显著变化。

首先，在灌浆后期至成熟期阶段，各模型的 RMSE 整体处于较高水平，其中 MLP 与原始 ELM 的误差增长尤为明显，而 IBA-ELM 与 BA-ELM 的误差增长幅度相对较小。这主要是由于该阶段作物逐渐进入生理成熟期，叶面积指数下降，蒸腾作用减弱，同时受气温波动、辐射变化及水分再分配等多重因素影响，ETc 呈现更强的非线性波动特征，使模型预测难度显著增加。在此情况下，经过群智能优化的 IBA-ELM 能够获得更优参数组合，从而保持较好的预测稳定性，体现出更强的非线性拟合能力。

其次，在拔节期、抽穗期及灌浆前期阶段，各模型 RMSE 整体较低，其中 IBA-ELM 始终保持最低或接近最低误差水平。这一阶段作物生长较为稳定，蒸散过程主要受辐射和温度等主导气象因子控制，系统非线性程度相对较低，使得数据驱动模型更容易学习其内在映射关系。同时，IBA 优化策略通过增强参数搜索的全局性和稳定性，使 ELM 能够获得更优的输入权重与隐层偏置，从而进一步降低预测误差。

进一步比较不同模型可以发现，IBA-ELM 在绝大多数生育阶段均表现出更低或更稳定的 RMSE 水平，而原始 ELM 与 MLP 在多个阶段出现明显误差波动，说明未经优化的模型参数难以充分刻画 ETc 的动态变化特征。相比之下，群智能优化方法通过全局搜索显著改善了模型参数配置，使模型能够更好适应不同生育阶段的复杂非线性关系。

综合分析可知，不同生育阶段的预测误差差异不仅反映了 ETc 本身的阶段性变化特征，同时也验证了 IBA-ELM 在参数优化和非线性拟合方面的有效性。所提出模型能够在蒸散过程复杂度较高的关键生育阶段仍保持较好的预测精度，体现出更强的鲁棒性与阶段适应能力。

2.3 本章小结

本章通过收敛曲线、消融实验、综合指标以及分阶段误差分析，对 IBA-ELM 模型进行了系统评估。

主要结论包括：

（1）群智能优化算法可显著提升 ELM 性能；

（2）精英策略对 IBA 收敛稳定性具有重要作用；

（3）IBA-ELM 在所有对比模型中取得最佳综合性能，其 R^2 指标最高，同时 RMSE 与 MAE 最低，表明所提出的改进策略能够有效提高模型预测精度与泛化能力；

（4）模型在成熟期阶段预测难度较大，误差显著高于其他阶段。

下一章将结合气象缺失情景，进一步分析模型在数据不完备条件下的泛化能力。

3 第六章气象数据缺失情景下的冬小麦 ETc 预测

在实际农业生产中，气象观测数据往往存在缺测或不完整情况。为评估 IBA-ELM 在不同输入条件下的鲁棒性与泛化能力，本章构建多种气象输入情景，并与经验公式 Hargreaves-Samani（H-S）方法进行对比分析，同时从相关性与敏感性角度探讨模型对气象因子的响应特征。

3.1 不同气象输入情景下的预测性能

为模拟气象数据缺失情形，构建三种输入情景：

- 情景 I（Scenario I）：完整气象因子输入；
- 情景 II（Scenario II）：不包含太阳辐射；
- 情景 III（Scenario III）：仅使用温度相关因子。

图 9 给出了三种情景下 IBA-ELM 的预测性能对比。

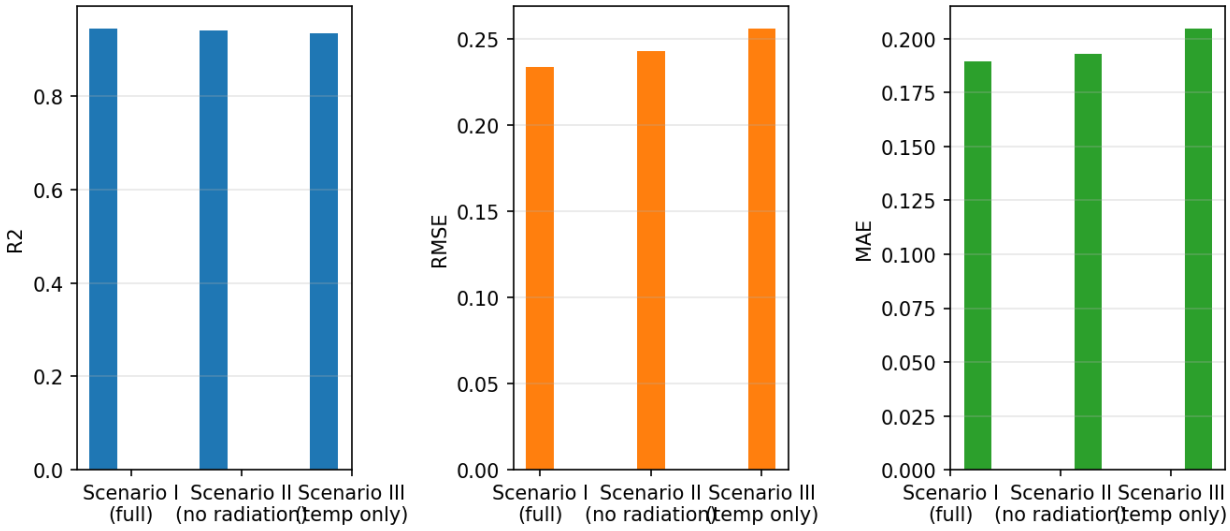

Figure 9: 不同气象输入情景下 IBA-ELM 的预测性能

Table 2: Prediction performance of IBA-ELM under different meteorological input scenarios

Scenario	Input features	R^2	RMSE	MAE
I	$T_{\text{mean}}, RH_{\text{mean}}, u_{2,\text{mean}}, Rs_{\text{mean}}, DOY, k_c$	**0.9455**	**0.2335**	**0.1896**
II	$T_{\text{mean}}, RH_{\text{mean}}, u_{2,\text{mean}}, DOY, k_c$	0.9410	0.2429	0.1932
III	$T_{\max}, T_{\min}, DOY$	0.9345	0.2560	0.2048

可以观察到：

（1）完整输入情景下 R^2 最高，RMSE 与 MAE 最低；

（2）移除辐射因子后，性能略有下降，但整体变化幅度有限；

（3）仅使用温度因子时，误差进一步增大，但模型仍保持较高 R^2 水平。

说明 IBA-ELM 对气象输入具有一定鲁棒性，在数据不完整条件下仍能维持较好的预测能力。

3.2 IBA-ELM 模型与传统经验公式的对比

Hargreaves-Samani 方法是一种基于温度的经验估算公式，常用于气象数据受限情形。为比较数据驱动模型与经验公式的差异，本节在温度输入条件下（Scenario III）对两者进行对比。

图 10 展示了 IBA-ELM 与 H-S 方法在 R^2、RMSE 与 MAE 指标下的对比结果，并给出预测-观测散点图。

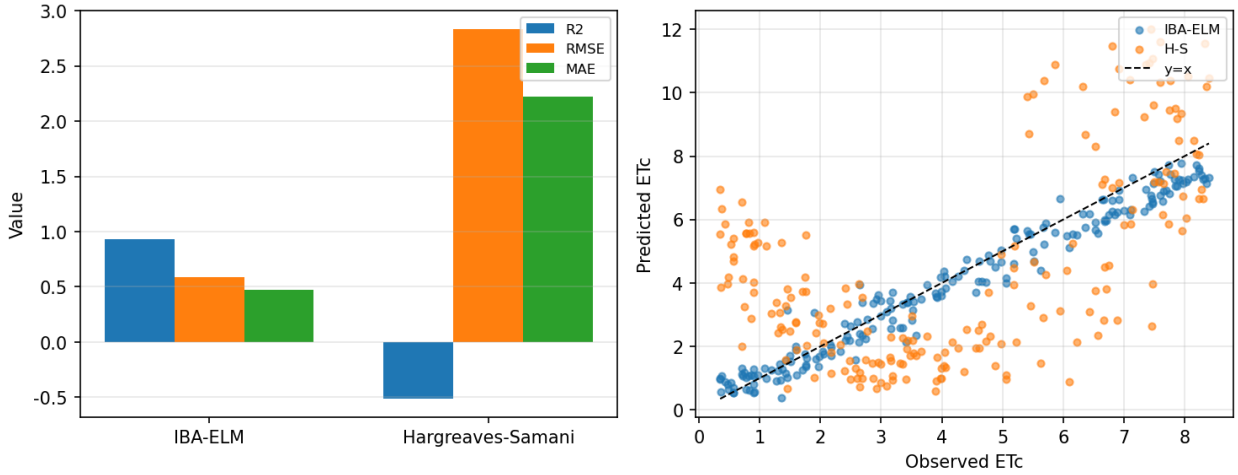

Figure 10: IBA-ELM 与 Hargreaves-Samani 方法对比（温度情景）

结果表明：

（1）IBA-ELM 在 R^2 上显著高于 H-S 方法；

（2）H-S 方法误差明显更大，RMSE 与 MAE 均高于 IBA-ELM；

（3）从散点分布看，IBA-ELM 预测点更接近 $y = x$ 参考线，而 H-S 方法偏离较为明显。

说明在仅有温度信息的情况下，数据驱动模型仍优于传统经验公式。

3.3 气象因子对冬小麦 ETc 的相关性与敏感性分析

为进一步理解模型行为，本节从两个角度进行分析：

（1）气象因子与 ETc 的线性相关性；

（2）模型对输入扰动的敏感性。

3.3.1 相关性分析

图 11 左图给出了主要气象因子与 ETc 的相关系数。

可以看到：

- 作物系数 k_c 与 ETc 呈强正相关；
- 辐射（Rs_mean）与风速（u_2_mean）为正相关；
- 相对湿度与降水呈负相关；
- 年积日（DOY）表现为明显负相关趋势。

说明 ETc 受辐射、作物生育进程及空气动力条件的显著影响。

3.3.2 敏感性分析

图 11 右图展示了在完整输入情景下，各因子增加 1 个标准差时输出变化的平均绝对幅度。

可以观察到：

- DOY 与 k_c 对模型输出影响最大；
- 辐射与温度影响中等；
- 风速与湿度敏感性相对较低。

该结果与相关性分析结论基本一致，说明模型内部响应机制与物理规律具有一致性。

3.4 本章小结

本章围绕气象数据缺失情景下的冬小麦 ETC 预测问题，对 IBA-ELM 模型的鲁棒性与适应能力进行了系统分析。主要结论如下：

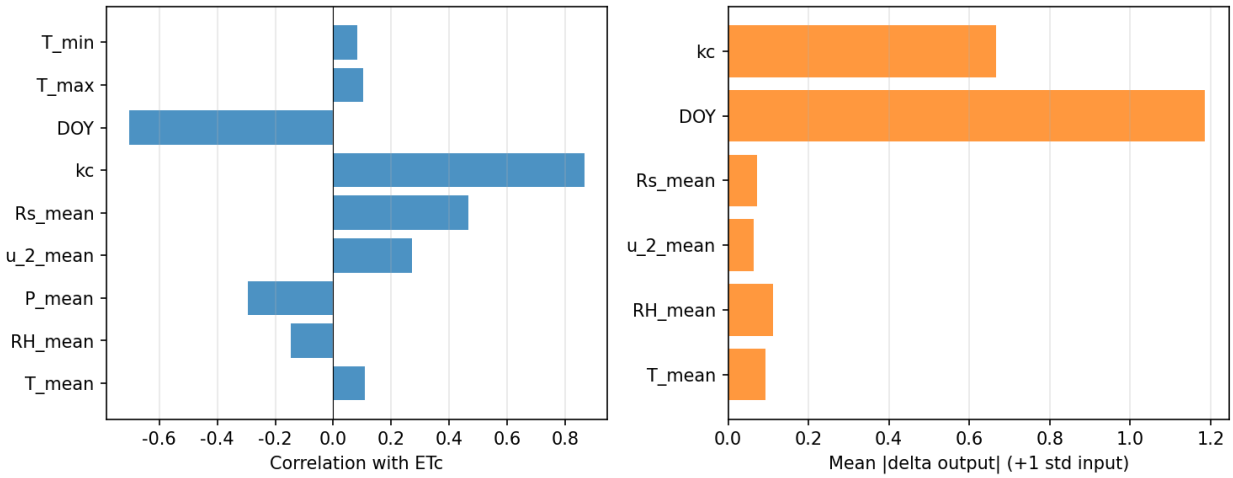

Figure 11: 气象因子相关性与敏感性分析

（1）IBA-ELM 在输入气象因子缺失的情况下仍保持较高预测精度，表明所提出模型具有较强鲁棒性；

（2）与传统 Hargreaves-Samani 经验公式相比，数据驱动模型在仅使用温度输入的情景下仍表现出更高预测精度，说明机器学习方法能够有效挖掘气象因子与蒸散量之间的非线性关系；

（3）相关性与敏感性分析结果表明，作物系数与生育进程因子对 ETc 影响最为显著，该结果与农业蒸散过程的物理机制一致，进一步验证了模型的合理性；

（4）辐射因子缺失对模型性能影响相对有限，而仅使用温度因子时模型误差有所增加，说明多源气象因子输入有助于提高预测精度。

综上所述，IBA-ELM 在气象数据不完备条件下仍具有良好的预测能力与鲁棒性，表明该方法在实际农业蒸散量预测任务中具有较高应用潜力。

然而，本研究仍存在一定局限性。一方面，IBA-ELM 的优化性能对种群规模、迭代次数及惯性权重等参数设置较为敏感，在迁移至其他区域或不同作物数据集时可能需要重新调整参数；另一方面，随着样本规模及隐层节点数增加，基于群智能的参数寻优过程将带来额外计算开销，可能影响模型训练效率。

未来研究可进一步探索自适应参数调节机制、并行化优化策略或轻量化群智能算法，以降低计算成本并提升模型跨场景适应能力，从而进一步增强其在农业蒸散量预测中的实用性与推广价值。